

I- Introduction :

De nos jours, l'informatique est devenue inséparable de la biologie. Pour gérer la masse énorme de données générées par la recherche scientifique, l'utilisation de logiciels libres et de plateformes de partage est essentielle. Ce rapport présente notre travail sur deux outils majeurs : Biopython, une bibliothèque de programmation qui aide à l'analyse des séquences biologiques, et Zenodo, un entrepôt mondial pour le stockage et la publication de données scientifiques. L'objectif est de comprendre comment ces outils facilitent le travail des chercheurs dans le cadre de la "Science Ouverte".

II- Partie I : étude théorique d'un outil :

1- Présentation générale de Biopython :

Biopython est un projet international collaboratif géré par des développeurs bénévoles et distribué en open source. Il s'agit d'une collection de bibliothèques Python conçues pour résoudre une vaste gamme de problèmes en bioinformatique et en biologie moléculaire computationnelle. Fondé en 1999, ce projet met à disposition des outils programmatiques pour faciliter le travail des chercheurs sans avoir à redévelopper des fonctions de base.

2- Fonctionnalités principales :

L'outil propose des modules variés permettant de réaliser les tâches suivantes :

- La lecture et l'écriture de nombreux formats de fichiers de séquences et d'alignements (comme FASTA, GenBank, EMBL, etc.).
- La manipulation de structures macromoléculaires en 3D via le module Bio.PDB.
- L'interaction avec des outils de bioinformatique classiques tels que BLAST, ClustalW et EMBOSS.
- L'accès direct à des bases de données biologiques en ligne, notamment NCBI Entrez, ExPASy et KEGG.
- La réalisation d'opérations biologiques courantes comme la transcription et la traduction de séquences d'ADN.
- L'analyse de génétique des populations et l'apprentissage statistique supervisé ou non.

3- Aspects techniques :

Biopython repose sur le langage Python, reconnu pour sa syntaxe simple et ses capacités de programmation orientée objet.

Pour optimiser les performances, la bibliothèque peut s'interfacer avec des codes écrits en C, C++ ou FORTRAN.

Elle s'appuie sur le projet NumPy pour gérer efficacement les calculs scientifiques numériques.

Le logiciel est multiplateforme, fonctionnant sur tous les systèmes d'exploitation majeurs.

4- Points forts et Accessibilité :

-Disponibilité : Le code source et la documentation sont accessibles gratuitement sur le site officiel (www.biopython.org) sous la licence Biopython.

-Fiabilité : C'est un outil mature utilisé dans plus de 100 publications scientifiques.

-Support : Le projet est soutenu par l'Open Bioinformatics Foundation (OBF) qui héberge son infrastructure technique.

5- Les points faibles (Limites) :

-Niveau requis : Il faut obligatoirement connaître les bases de la programmation en Python.

-Vitesse : Pour des calculs extrêmement lourds sur des génomes entiers, il peut être un peu lent comparé à des outils écrits uniquement en C++.

6- Conclusion :

Pour conclure, Biopython est devenu un outil indispensable pour nous. Il permet de gagner un temps fou en automatisant les tâches répétitives sur les données biologiques. C'est le lien parfait entre l'informatique et la biologie.

Référence :

Cock, P. J., Antao, T., Chang, J. T., Chapman, B. A., Cox, C. J., Dalke, A., ... & de Hoon, M. J. (2009). Biopython: freely available Python tools for computational molecular biology and bioinformatics. *Bioinformatics*, 25(11), 1422-1423.

-<https://biopython.org/wiki/Documentation>.

III- Partie II : étude pratique : exploration de Zenodo :

1- Présentation de Zenodo :

A- Objectifs de la plateforme :

Zenodo est un entrepôt de données de recherche en libre accès (Open Access). Lancé par le CERN dans le cadre du projet européen OpenAIRE, il permet aux chercheurs du monde entier de déposer, de conserver et de partager leurs résultats de recherche, quel que soit leur format ou leur domaine scientifique.

B- Types de contenus hébergés :

La plateforme accueille une grande diversité de contenus numériques, notamment :

- Datasets : Ensembles de données brutes ou traitées.
- Publications : Articles scientifiques, thèses et rapports techniques.
- Logiciels : Codes sources et scripts de recherche.
- Images et Vidéos : Documents multimédias liés à l'expérimentation.

C- Intérêt pour la science ouverte et la biologie :

Pour les sciences de la nature et de la vie, Zenodo joue un rôle crucial en favorisant la reproductibilité des expériences. En attribuant un DOI (Digital Object Identifier) à chaque dépôt, il garantit que les données sont citables, pérennes et facilement accessibles par la communauté scientifique mondiale, ce qui accélère la collaboration et l'avancement des découvertes biologiques.


<https://zenodo.org/>
<https://about.zenodo.org/>

2- Description des étapes réalisées :


- Comment j'ai fait ma recherche (Étapes suivies) :

A- Étape de recherche :

J'ai commencé par aller sur le site zenodo.org. Pour mon test, j'ai utilisé le mot-clé "cell" dans la barre de recherche.




-commentaire : Accès à la barre de recherche du portail Zenodo et saisie du mot-clé 'Cell' pour filtrer les jeux de données biologiques disponibles.



-Commentaire : Application d'un filtre de recherche à gauche pour limiter les résultats aux 'Datasets' uniquement, afin d'extraire des données brutes exploitables sur les cellules.

- Pourquoi ce choix ? (Critères de sélection) :



-Commentaire : Après avoir filtré les résultats, j'ai sélectionné ce dataset spécifique sur les cellules car il contient des données récentes et une description détaillée qui correspond à l'objectif de notre travail.



B- Critères de sélection du fichier :

Pour garantir la qualité de ce travail, le choix du Dataset s'est basé sur les critères suivants :

- Pertinence : Le fichier est directement lié au mot-clé choisi (Cell).
- Format : Sélection exclusive d'un "Dataset" pour obtenir des données brutes.
- Open Access : Le fichier est accessible gratuitement et sans restrictions.
- Identifiant DOI : Présence d'un DOI pour garantir la traçabilité de la source.
- Actualité : Choix d'un fichier récent pour assurer des données scientifiques à jour.
- Fiabilité : Vérification de la crédibilité de la source (auteur ou institution de recherche).

C- Navigation et téléchargement :

Pour récupérer le fichier, c'était assez simple. J'ai cliqué sur le titre, puis j'ai fait défiler la page vers le bas jusqu'à la partie "Files". Là, j'ai cliqué sur le bouton



-commentaire : C'est ici que j'ai téléchargé le fichier final après avoir exploré les détails de la page.

3- Métadonnées du dataset :

Nom utilisée : Dublin core.

Elément Dublin core	discreption
Title	Classification of blood cells dynamics with convolutional and recurrent neural networks : a sickle cell disease case study
Créator	Darrin Maxime1.Samudre Ashwin2.Sahun Maxime2.Atwell Scott2.Badens Catherine3.Charrier Anne2.Helfer Emmanuele2.Viallat Annie2.Cohen-Addad Vincent4.Giffard-Roisin Sophie5
Sujet	Blood cells, sickle cell disease, deep learning, CNN, RNN
Publisher	Zenodo
Contributeur	Chercheurs and ingénieurs and intelligence artificielle
Date	24.2021
Type	Dataset
Format	Fichiers CSV
Identifiant	DIO 10.5281 https://doi.org/10.5281/zenodo.5723606
Language	English
Right	Créative Commons Attribution 4.0 International